

aelion

Régression

Régression linéaire & logistique

- Modèle prédictif : fonction mathématique qui associe à chaque donnée x une prédiction $h(x)$
 - Exemple simple : $y = ax+b$
 - Fonction h dépend d'un vecteur de paramètres θ
- Fonction de coût (loss) : mesure l'erreur globale entre les prédictions $h(x)$ et les vraies valeurs
- Objectif : trouver les paramètres θ qui minimisent la fonction de coût

- On suppose que la fonction prédictive est de forme :

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_3 + \dots + \theta_n x_n$$



- Chaque x_i est une feature

- Fonction de coût :

$$\sum_{i=1}^m (h_{\theta}(x_i) - y_i)^2$$

- Les coefficients sont optimisés grâce à la descente du gradient

A chaque itération, on met à jour chaque paramètre de θ en soustrayant sa dérivée partielle multipliée par le taux d'apprentissage



- Si les features ont des échelles différentes, la convergence risque d'être très lente !
- Normalisation : on enlève la moyenne => nouvelle moyenne en 0
- Standardisation : on divise par l'écart-type => nouvel écart-type égal à 1

$$X_{stand} = \frac{X - \mu}{\sigma}$$

- Eviter l'overfitting = réduire la complexité du modèle
- Coefficients θ_n les plus faibles possibles
- Pénalisation de la fonction de coût plus les θ_n sont élevés

$$\frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^n \theta_j^2$$

- Pénalisation :
 - Somme des carrés (L2 norm) : Ridge Regression
 - Somme des valeurs absolues (L1 norm) : Lasso Regression
 - Les deux : ElasticNet

- La régression linéaire simple ne permet que des fonctions affines !
- Pour complexifier le modèle, on peut construire une fonction polynomiale :


$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1 x_2 + \theta_4 x_1^2 + \theta_5 \sqrt{x_1} \dots$$

Et pour la classification ?

- Valeur cible = variable continue
- Classification ?
- Valeur cible = probabilité d'appartenir à la classe Positive = $p(x)$
- Transformer variable continue pour qu'elle soit comprise entre 0 et 1

Fonction Sigmoidale (Fonction Logistique)

aelion.fr



- Output $y = 1$ ou 0 (classe Positive ou Négative)
- Quand $y = 0$:
 - $1 - h(x)$ = augmente plus l'erreur diminue
 - $-\log(1 - h(x))$ = pénalise les fortes erreurs
- Quand $y = 1$:
 - $h(x)$ = augmente plus l'erreur diminue
 - $-\log(h(x))$ = pénalise les fortes erreurs
- Synthèse : $\sum_{i=1}^m -y_i * \log(h(x_i)) - (1 - y_i) * \log(1 - h(x_i))$

- Régression logistique = classifieur binaire
- Algorithme « one-versus-all » :
 - Pour chaque classe, on estime $p(x)$ la probabilité que x appartienne à cette classe plutôt qu'à n'importe quelle autre
 - On retient la classe avec la probabilité la plus élevée



aelion

95 chemin de Gabardie 31200 Toulouse
05 61 49 42 60 - contact@aelion.fr

aelion.fr

