



aelion

Arbres de décision

Classification & régression






Objectif : trouver les conditions qui permettent de bien séparer les classes

Mesurer le taux de séparation

- Classifieur binaire :
 - p = proportion de la classe A
 - $1 - p$ = proportion de la classe B
 - Impureté de Gini : $p * (1 - p)$
- Forme en cloche




Autres critères d'impureté

- Gini : extension au multi-classe
- Entropie


$$I_G(D) = \sum p_i(1 - p_i)$$

$$I_E(D) = \sum p_i \log_2(p_i)$$

$$I_C(D) = 1 - \max(p_1, p_2, \dots, p_k)$$



Construction de l'arbre





Trouver le bon split

aelion.fr



aelion

- Lister tous les splits possibles
- Pour chaque split :
 - Mesurer le critère d'impureté sur chacun des deux sous-ensembles créés
 - Prendre la moyenne pondérée
- Choisir le meilleur split
- Recommencer sur chacun des sous-ensembles

Séparation des données




Partitionnement de l'espace



- Feuille avec peu d'éléments = peu généralisable
- Critères d'arrêt forcés :
 - Profondeur maximale
 - Nombre minimum d'élément par feuille
 - Nombre de nœuds maximum
 - Gain minimum du critère d'impureté
- Prédiction de la classe majoritaire

- On remplace le critère d'impureté par la variance
- Prédiction = valeur moyenne
- Effet « discret » des prédictions



- Avantages :
 - Facile à comprendre (interprétables)
 - Résistant aux valeurs aberrantes (outliers)
 - Peut modéliser des relations non-linéaires
 - Traite valeurs numériques et catégorielles
 - Pas besoin de normaliser et standardiser les features
- Inconvénients :
 - Attention à l'overfitting
 - Très forte instabilité
 - Considère chaque feature séparément



aelion

95 chemin de Gabardie 31200 Toulouse
05 61 49 42 60 - contact@aelion.fr

aelion.fr

