

aelion

Random Forests

Ensemble methods


Le problème des arbres de décision

aelion.fr

- Les arbres de décision sont instables !
 - Égalité dans le critère d'impureté
 - Petite variation dans le training set
- Cette instabilité les rend inutilisables en pratique
- Sans oublier une forte tendance à l'overfitting

- Bagging = **bootstrap aggregating**
- Bootstrap : échantillonnages aléatoires avec remise :
 - Modèles construits sur ces sous-ensembles
 - Chaque modèle est plus faible...
 - Mais les modèles (et leurs erreurs) sont plus indépendants !
- Aggregating : ensemble des modèles :
 - Vote (classification) ou moyenne (régression)
 - Les modèles corrigent les erreurs des autres !

Bagging (illustration)



- Bagging d'arbres de décision :
 - Utilise l'instabilité des arbres pour créer des modèles indépendants
 - Améliore les performances
 - Corrige l'instabilité !
- Echantillonnage :
 - Des données
 - Des features

- Très bons résultats sur tout type de données
- Peu d'hyper-paramètres
- Rapide à calculer et parallélisable
- Bonne gestion :
 - Des données catégorielles
 - Des outliers
 - Des dimensionnalités élevées si peu de valeurs possibles par feature
- Faible tendance à l'overfitting
- Couteau-suisse des algorithmes à utiliser sans modération !



aelion

95 chemin de Gabardie 31200 Toulouse
05 61 49 42 60 - contact@aelion.fr

aelion.fr

