

# aelion

## Préparation d'un dataset d'images

Vision industrielle : données pour la détection d'anomalies

aelien

01

Structure du dataset



Découpage et logique normal / défaut

# L'image comme donnée

**Une image = matrice de pixels ( $H \times L \times \text{canaux}$ )**

- Niveaux de gris : 1 canal · couleur RVB : 3 canaux
- En vision industrielle, l'image varie selon l'éclairage, l'angle, le capteur, l'arrière-plan

**Un dataset propre et représentatif est la condition n°1 d'un modèle fiable**

# Découpage train / validation / test

aelion.fr

- Train : apprentissage des poids du modèle
- Validation : réglage des hyperparamètres et early stopping
- Test : évaluation finale, jamais vu pendant l'entraînement

## Pièges à éviter :

- fuite de données (data leakage) entre les jeux
- images d'une même pièce / série réparties dans plusieurs jeux
- proportions non représentatives de la réalité

# Spécificité de la détection d'anomalies

aelion.fr

**On dispose de beaucoup d'images « normales » et de très peu de défauts**

**Conséquence sur le découpage :**

- train = images normales uniquement (le modèle apprend la « normalité »)
- validation / test = mélange de normales et de défauts pour mesurer la détection
- Les rares défauts disponibles sont précieux : on les réserve à l'évaluation

# 02

## Prétraitement



Redimensionnement et normalisation

# Redimensionnement

- Le réseau attend une taille d'entrée fixe (ex. 256×256)
- Préserver le ratio quand c'est possible (padding plutôt que déformation)
- Choisir une résolution suffisante pour que le défaut reste visible
- Méthodes d'interpolation : bilinéaire, bicubique, plus proche voisin

# Normalisation des pixels

**Mettre les valeurs à la même échelle pour stabiliser et accélérer la convergence**

- Mise à l'échelle  $[0, 1]$  : division par 255
- Standardisation :  $(x - \text{moyenne}) / \text{écart-type}$ , par canal
- Statistiques calculées sur le train uniquement, puis appliquées partout

# 03


## Augmentation




Générer de la variété, sans tricher

# Augmentation de données


**Original**




**Rotation**




**Miroir**




**Luminosité**



**Bruit**



**Recadrage**



# Principes et précautions

aelion.fr

**Objectif : plus de variété → meilleure robustesse et généralisation**

- Transformations géométriques : rotation, miroir, recadrage, zoom
- Transformations photométriques : luminosité, contraste, bruit, flou

**Précautions en vision industrielle :**

- ne pas créer de faux défauts ni masquer un vrai défaut
- rester cohérent avec la physique du procédé (orientation, échelle)
- n'augmenter que le train, jamais le test
- Outils : Albumentations, tf.image / Keras, torchvision

# 04

## Déséquilibre & étiquettes



Gérer la rareté des défauts

# Le déséquilibre des classes


aelion.fr

**Les défauts sont rares : un modèle peut atteindre 99 % d'accuracy en ignorant tous les défauts**

## Stratégies :

- suréchantillonnage / augmentation ciblée des défauts
- pondération des classes dans la fonction de coût
- choisir des métriques adaptées (rappel, F1) plutôt que l'accuracy

**L'approche par auto-encodeur contourne le problème : on n'apprend que le normal**



# Qualité des étiquettes

aelion.fr

**Une étiquette = la vérité terrain ; sa qualité plafonne celle du modèle**

- Niveaux d'annotation : étiquette image, boîte englobante, masque pixel
- Cohérence inter-annotateurs : définir une convention claire (qu'est-ce qu'un défaut ?)
- Tracer les cas ambigus et les faire arbitrer par un expert métier
- **En anomalie non supervisée : peu ou pas d'étiquettes de défaut requises pour l'entraînement**

# 05

## Versioning



Reproductibilité et traçabilité des données

# Versionner un dataset image

aelion.fr

**Pourquoi : reproductibilité, traçabilité, collaboration, retour arrière**

**Quoi versionner :**

- les images (souvent hors Git, via un stockage dédié)
- les métadonnées : source, date, capteur, conditions de prise de vue
- les artefacts : découpage train/val/test, statistiques de normalisation, étiquettes
- Outils : DVC, Git-LFS, conventions de nommage + fichier de métadonnées

**Règle d'or : un même identifiant de version doit toujours produire le même dataset**



**aelion**

95 chemin de Gabardie 31200 Toulouse  
05 61 49 42 60 - [contact@aelion.fr](mailto:contact@aelion.fr)

[aelion.fr](https://aelion.fr)

