

aelion

Risques éthiques & robustesse

Vision industrielle — biais, dérives, garde-fous

01

Risques spécifiques



Biais, dérives et confidentialité

Les biais

Un modèle apprend ce qu'on lui montre, et seulement cela

- Dataset non représentatif : un type de pièce, un éclairage, une ligne de production sur-représentés
- **Conséquence : bonnes performances en test, échec en conditions réelles**
- Bonnes pratiques : auditer la composition du dataset, documenter les conditions de collecte

Les dérives (drift)

- Data drift : les images de production changent (nouvelle caméra, usure, saison, lot)
- Concept drift : la définition de « normal » ou de « défaut » évolue dans le temps
- Exemple : un détecteur d'objets (YOLO) performant se dégrade silencieusement quand le contexte change
- Parade : surveiller les performances en continu et ré-entraîner périodiquement

La confidentialité

aelion.fr

Les images peuvent contenir des données sensibles : visages, plaques, informations propriétaires

- Cadre réglementaire : RGPD pour toute donnée personnelle identifiable
- Mesures : anonymisation / floutage, minimisation des données, accès restreint
- Secret industriel : sécuriser le stockage et les échanges (clients, sous-traitants)

02

Robustesse



Données hors distribution et qualité capteur

Données hors distribution (OOD)

aelion.fr

Une donnée OOD est très différente de tout ce que le modèle a vu à l'entraînement

- Exemples : nouveau type de pièce, objet inattendu, image corrompue
- **Risque : le modèle produit une prédiction confiante mais fausse**
- **Atout de l'auto-encodeur : une entrée OOD se reconstruit mal → erreur élevée → signal d'alerte**

Qualité des capteurs et des caméras

aelion.fr

Le maillon faible d'un système de vision est souvent l'acquisition, pas le modèle

- Sources de dégradation : éclairage variable, flou, poussière, reflets, vibrations
- Une caméra mal calibrée crée de fausses anomalies (faux positifs)
- Bonnes pratiques : standardiser l'éclairage, contrôler le cadrage, maintenance et nettoyage réguliers

03

Attaques adversariales



Sensibilisation

Comprendre la menace

aelion.fr

Une attaque adversariale = une perturbation minime, souvent imperceptible à l'œil, qui trompe le modèle

- En vision : quelques pixels modifiés peuvent inverser une décision
- Vecteurs possibles : image numérique altérée, ou objet physique (autocollant, motif)
- **Premières parades : détection d'OOD, contrôle d'intégrité des entrées, supervision humaine**

aelien

04

Garde-fous



Usage responsable et limites

Définir des garde-fous

aelion.fr

- Seuils de décision : ne pas alerter sur la moindre erreur ; calibrer faux positifs vs faux négatifs
- **Human in the loop : l'humain valide les cas incertains ou critiques**
- Limites d'usage : documenter ce que le système ne sait pas faire (cas exclus)
- Plan de repli : que se passe-t-il si le modèle est indisponible ou peu sûr ?

Adapter la solution aux enjeux

aelion.fr

Aligner la solution sur le besoin client et les enjeux sociétaux

- Arbitrer le coût d'un faux positif (arrêt inutile) contre un faux négatif (défaut non détecté)
- Transparence : expliquer les décisions, tracer les alertes
- **Responsabilité : définir qui décide en dernier ressort et qui est garant du système**



aelion

95 chemin de Gabardie 31200 Toulouse
05 61 49 42 60 - contact@aelion.fr

aelion.fr

