

Sujet d'examen

Cas d'usage : Créer une solution IA de recommandation de Marketing personnalisée.

1. Contexte général

Vous travaillez au sein d'une grande entreprise de e-commerce qui souhaite développer une **IA de recommandation marketing personnalisée**.

Les objectifs de cette IA sont :

- proposer aux clients des **offres et produits adaptés en temps réel**,
- améliorer la **conversion**, le **panier moyen** et la **fidélisation**,
- respecter les **contraintes de confidentialité, d'éthique et de conformité RGPD**.

Votre mission consiste à **concevoir, documenter, modéliser et proposer une stratégie d'industrialisation** de cette solution d'IA.

Un dataset marketing est fourni séparément et doit être exploité dans le cadre du notebook.

2. Données du projet – Dataset marketing

Le dataset fourni **marketing_reco_dataset.csv** contient des informations anonymisées sur des clients, leurs comportements de navigation et leurs interactions avec les recommandations.

2.1 Colonnes du dataset

Chaque ligne représente un **profil client + une session de navigation**. Le fichier contient notamment :

- **customer_id** : identifiant client anonymisé
- **session_id** : identifiant de session
- **age** : tranche d'âge ou âge approximatif
- **gender** : F / M / autre / non communiqué
- **country** : pays (code ou libellé)
- **device_type** : mobile, desktop, tablette
- **traffic_source** : canal d'acquisition (email, ads, direct, social, organic...)
- **visits_last_30d** : nombre de visites sur les 30 derniers jours
- **total_spent_last_6m** : montant total dépensé sur les 6 derniers mois
- **avg_basket_value** : panier moyen
- **segment_marketing** : nouveau client, fidèle, VIP, churning...
- **last_category_viewed** : dernière catégorie consultée (mode, high-tech, maison...)
- **last_product_price** : prix du dernier produit consulté
- **discount_sensitivity** : sensibilité à la remise (faible / moyenne / forte)
- **email_optin** : 0/1 (inscrit à la newsletter ou non)

- **push_optin** : 0/1 (notifications push autorisées)
- **reco_shown** : 0/1 (une recommandation IA a été affichée lors de la session)
- **reco_clicked** : 0/1 (la recommandation a été cliquée)
- **purchased_after_reco** : 0/1 (achat suite à la recommandation)
- **time_on_site_sec** : temps passé sur le site durant la session
- **churn_risk** : estimation du risque de churn (faible / moyen / élevé)

Le candidat peut :

- filtrer ou enrichir les données,
 - créer de nouvelles variables (score d'engagement, RFM, etc.),
 - regrouper les catégories,
- à condition de **documenter toutes les transformations** dans le notebook.

3. Travail attendu : Votre Notebook

Le candidat doit produire un **notebook complet** (Jupyter), contenant du code exécutable, du texte explicatif, des graphiques et un journal de bord :

3.1 Documentation du projet

- Description du cas d'usage marketing (e-commerce, recommandation temps réel).
- Inventaire des sources de données (CRM, historique d'achats, navigation, campagnes).
- Définition d'une **datasheet marketing** :
 - variables collectées
 - bases légales de traitement (RGPD)
 - biais potentiels (sous-représentation de certains profils)
 - limites (saisonnalité, données manquantes, cookies refusés)

3.2 Préparation et qualité des données

- Nettoyage : valeurs manquantes, aberrantes, doublons.
- Normalisation des variables monétaires et de fréquence.
- Encodage des variables catégorielles (one-hot, ordinal, embeddings...).
- Segmentation initiale des clients (RFM, segments marketing, scoring d'engagement).
- Gestion de l'équilibre des classes (ex : clients ayant cliqué vs non cliqué, acheté vs non acheté).

3.3 Choix du modèle d'IA

Le candidat doit proposer un ou des modèles d'IA :

- filtrage collaboratif (user-based / item-based),
- modèles séquentiels (RNN, Transformer) pour séquences d'achats,
- modèles de ranking (learning to rank),
- modèles de classification ou de scoring (probabilité de clic / conversion).

Il devra justifier :

- pourquoi ce(s) modèle(s) est/sont adapté(s) au contexte,
- comment il(s) prend/prennent en compte la personnalisation,
- comment ils s'intègrent dans un tunnel marketing sans générer de saturation (spam publicitaire).

3.4 Entraînement, tests et performance

- Constitution d'un jeu d'entraînement et de test.
- Choix des métriques : CTR (taux de clic), conversion, uplift, panier moyen, taux de désabonnement.
- Analyse de cas : un modèle très performant court terme peut-il être toxique long terme (image de marque, fatigue publicitaire) ?

3.5 Implémentation et architecture

- Prototype d'API de recommandation (par ex. FastAPI, Flask).
- Intégration dans le site web et l'application mobile :
 - points d'appel,
 - latence acceptable,
 - capacité à gérer le temps réel.
- Proposition d'une **architecture MLOps** :
 - pipeline de mise à jour des modèles,
 - suivi des performances,
 - A/B testing permanent,
 - gestion des dérives (changement des comportements d'achat).

3.6 Gestion des risques et éthique

- Identification des risques :
 - biais de recommandation (toujours les mêmes produits mis en avant),
 - invasion de la vie privée,
 - micro-manipulation (dark patterns).
- Propositions de garde-fous :
 - respect strict du RGPD,
 - paramétrage des préférences utilisateur,
 - transparence des recommandations ("Pourquoi ce produit ?").

4. Votre Livrable

Vous devez envoyer votre livrable à la responsable d'examen stephanie.lamoureux@aelion.fr avant le 09/01/2026 avec accusé de réception, dans un fichier zip nommé [NOM prenom du candidat_livrable soutenance orale] :

Contenu de votre livrable :

1/ Votre Notebook Jupyter (.ipynb) comprenant 2 sous-parties (OBLIGATOIRE) :

✓ PARTIE 1 : La production du cas d'usage

Qui mettra en avant à minima vos travaux autour de :

- La préparation des données
- L'analyse exploratoire
- Les transformations
- Le choix du modèle IA
- L'entraînement
- La performance
- Les visualisations
- Les limites et amélioration

✓ PARTIE 2 : Le journal de bord

Il doit consigner, **dans le détail**, la méthode et les choix adoptés à différentes étapes du travail sur le cas d'usage, pour rendre compte du raisonnement et du cheminement de la réflexion, et doit inclure :

- La démarche adoptée étape par étape
- Les choix techniques et leurs justifications
- Les décisions abandonnées + raisons
- Les difficultés rencontrées et comment elles ont été traitées
- Les risques, biais, limites identifiés en cours de route
- Les pistes d'amélioration envisagées

2/ Votre Support de soutenance au format PPF ou PDF (OBLIGATOIRE)

Votre support doit présenter clairement :

- Le cas d'usage (contexte, objectif, besoin métier)
- Votre démarche (jeux de données, transformation, modèle IA retenu, justification de vos décisions)
- Choix du modèle + l'entraînement (modèle, hyperparamètres, logique scientifique)
- La performance (résultats, interprétation, impact métier)
- Risques, limites, biais (risques éthiques, biais de données, amélioration continue)

5. Déroulement de votre soutenance orale :

- Elle se déroulera en visio :
 - 30 minutes de présentation du cas d'usage et de la solution IA,
 - 30 minutes de questions avec un jury composé de **deux professionnels externes**.