

# INDUSENSE | Optimisation de la Random Forest

Maintenance prédictive a 24 h | Synthèse pédagogique du TP | Random Search et MLflow

**Question : le tuning améliore-t-il le modèle ? Réponse : il améliore le score interne de validation croisée, mais pas l'Average Precision sur le test. La référence ne doit donc pas être remplacée sur la base de cette expérience.**

## 1. Ce que le modèle prédit et ce qui est optimisé

**Unité : la machine-heure.** Une ligne décrit une machine pendant une heure. La cible vaut 1 si une panne survient dans les 24 h suivantes. Une même panne peut rendre positives plusieurs heures : les 3 478 positifs du test ne sont pas 3 478 pannes distinctes.

**Objet du tuning.** La famille Random Forest avait déjà été choisie. Le Random Search ne modifie pas une forêt existante : chaque configuration et chaque fold entraînent une nouvelle forêt depuis zéro. Les hyperparamètres sont les réglages fixés avant cet apprentissage.

## 2. Méthode, espace et protocole sans fuite temporelle

**Pourquoi Random Search ?** 16 configurations sont tirées avec la graine 42 parmi 64 combinaisons. Le budget reste fixé et couvre plusieurs zones de l'espace. Grid Search aurait testé les 64 combinaisons ; Optuna aurait adapté ses propositions aux essais précédents, au prix d'une logique supplémentaire peu utile pour ce petit espace discret. Limite : le tirage aléatoire peut manquer la meilleure combinaison.

| Hyperparamètre   | Valeurs      | Rôle et compromis                                                   |
|------------------|--------------|---------------------------------------------------------------------|
| n_estimators     | 150, 300     | Nombre d'arbres : stabilité potentielle contre temps et taille.     |
| max_depth        | 6, 8, 12, 16 | Profondeur des arbres : finesse contre risque d'apprendre le bruit. |
| min_samples_leaf | 2, 5, 10, 20 | Minimum de lignes par feuille : une valeur élevée lisse les règles. |
| max_features     | sqrt, 0,25   | Variables candidates par séparation : 9 sur 88 ou 22 sur 88.        |

**Ordre réel :** (1) le train est découpé en 3 folds chronologiques expansifs ; (2) tous les enregistrements d'un timestamp restent ensemble ; (3) un gap de 24 h et une purge de 360 lignes protègent les frontières, car la cible regarde 24 h dans le futur ; (4) l'imputation médiane est apprise dans chaque fold ; (5) l'**Average Precision (AP)** moyenne choisit la configuration ; (6) le seuil F2 est fixé sur la validation dédiée ; (7) le test n'est lu qu'après le gel de ces choix. L'AP mesure la qualité du classement précision-rappel : AP = 0,60 ne signifie pas 60 % de bonnes prédictions.

## 3. Résultats : le gain interne ne se confirme pas sur le test

| Indicateur             | Référence       | Optimisé        | Interprétation                                                                   |
|------------------------|-----------------|-----------------|----------------------------------------------------------------------------------|
| AP CV moyenne          | 0.5575          | 0.5652          | +0,0077 en sélection interne : le Random Search choisit bien ce candidat.        |
| Dispersion entre folds | 0.0552          | 0.0545          | Variabilité proche ; ce n'est pas un intervalle de confiance.                    |
| Écart AP train - CV    | 0.3563          | 0.1635          | Écart réduit : risque de surapprentissage moindre, pas preuve de généralisation. |
| AP test                | 0.6151          | 0.5971          | -0,0180 : le progrès interne ne se retrouve pas sur la période de test.          |
| Précision / rappel     | 34.74% / 67.68% | 34.36% / 67.71% | Moins d'alertes correctes ; rappel presque identique.                            |
| F2 / seuil             | 0.5689 / 0.3299 | 0.5670 / 0.3494 | F2 favorise le rappel ; chaque seuil a été fixé sur validation.                  |

**Configurations comparées.** Référence : 300 arbres, profondeur 12, feuille 5, sqrt. Gagnant : 150 arbres, profondeur 6, feuille 10, max\_features = 0.25. Le gain CV est le critère de sélection ; le test sert ensuite à vérifier la généralisation.

## 4. Matrices de confusion et conséquence métier

| Référence    | Pred. normal | Pred. alerte | Optimisé     | Pred. normal | Pred. alerte |
|--------------|--------------|--------------|--------------|--------------|--------------|
| Réel normal  | VN 12 244    | FP 4 423     | Réel normal  | VN 12 168    | FP 4 499     |
| Réel positif | FN 1 124     | VP 2 354     | Réel positif | FN 1 123     | VP 2 355     |

**Effet concret : le modèle optimisé génère 76 fausses alertes supplémentaires pour une seule machine-heure positive supplémentaire détectée. Ce n'est pas nécessairement une panne distincte détectée en plus. Il faut donc évaluer aussi les incidents et les alertes consécutives.**

## 5. Influence, traçabilité et décision

**Influence et coût.** max\_depth est localement le plus sensible (amplitude AP 0.0103). Un seul réglage varie à la fois : les interactions ne sont pas toutes mesurées. La campagne comprend 23 configurations distinctes et 92 fits en 21.9 min. Un fit est un apprentissage complet. Énergie et CO2 non mesurés.

**Décision et limites.** Ne pas remplacer la référence sur ce test. Le test avait déjà été consulté, donc il ne constitue plus une vérification totalement indépendante. Confirmer sur une période future jamais utilisée, puis mesurer les pannes distinctes et le coût des alertes. MLflow conserve paramètres, scores, modèles, versions et empreinte du CSV ; il trace l'expérience sans garantir sa qualité.